

Sistema de Ruteo Resiliente ante Inundaciones Urbanas: Un Enfoque Multi-Algoritmo con Probabilidades de Falla Dinámicas Basado en Sistemas de Información Geográfica

Felipe Aros
Universidad Diego Portales
Santiago, Chile
felipe.aros1@mail.udp.cl

Resumen—Las inundaciones urbanas representan una amenaza creciente para la movilidad en ciudades latinoamericanas, especialmente en contextos de cambio climático. Este trabajo presenta el diseño, implementación y evaluación de un sistema de ruteo resiliente para entornos urbanos con riesgo de inundación en Santiago de Chile. El sistema integra datos de OpenStreetMap para la infraestructura vial, fuentes gubernamentales chilenas (DGA, SERNAGEOMIN) para amenazas hidrometeorológicas, y metadata ambiental (elevación SRTM, precipitación, cobertura de suelo) para calcular probabilidades de falla dinámicas en cada segmento de la red vial. Se implementaron y compararon cuatro algoritmos de ruteo: Dijkstra clásico como baseline, Dijkstra con costos resilientes, optimización mediante programación lineal entera mixta (MILP) usando CPLEX, y A* con heurística de riesgo. La plataforma web desarrollada con Next.js, PostgreSQL/-PostGIS y pgRouting permite visualizar simultáneamente las cuatro rutas calculadas, comparar métricas de distancia, riesgo y tiempo de cómputo, y simular escenarios de falla. Los resultados experimentales sobre una red de 28,208 nodos y 33,947 aristas demuestran que el enfoque resiliente reduce la exposición a zonas de riesgo en más del 50% con incrementos moderados en distancia (menos del 10%), validando la hipótesis de que es factible mejorar significativamente la resiliencia del transporte urbano mediante sistemas de información geográfica inteligentes.

Index Terms—Ruteo resiliente, inundaciones urbanas, sistemas de información geográfica, optimización combinatoria, pgRouting, PostGIS, programación lineal entera mixta, metaheurísticas

I. INTRODUCCIÓN

El cambio climático ha intensificado la frecuencia y severidad de eventos hidrometeorológicos extremos en zonas urbanas de todo el mundo. Según el Sexto Informe de Evaluación del Panel Intergubernamental sobre Cambio Climático (IPCC), las precipitaciones extremas han aumentado su intensidad en aproximadamente un 7% por cada grado Celsius de calentamiento global, con impactos particularmente severos en áreas urbanas donde la impermeabilización del suelo reduce drásticamente la capacidad de absorción (IPCC, 2021).

En América Latina, las ciudades enfrentan desafíos adicionales debido a la combinación de crecimiento urbano acelerado, infraestructura de drenaje insuficiente y topografía

compleja. Santiago de Chile ejemplifica esta problemática: una metrópolis de más de 7 millones de habitantes ubicada en un valle rodeado de montañas, donde las quebradas andinas canalizan escorrentías que históricamente han causado inundaciones devastadoras en sectores residenciales y vías de transporte críticas.

El Servicio Nacional de Geología y Minería de Chile (SERNAGEOMIN) ha identificado 47 zonas de alto riesgo de inundación en la Región Metropolitana, incluyendo áreas adyacentes al río Mapocho, el Zanjón de la Aguada, y quebradas como Macul, Lo Canas y San Ramón (SERNAGEOMIN, 2020). Estas zonas coinciden frecuentemente con corredores de transporte importantes, creando vulnerabilidades críticas para la movilidad urbana durante eventos de precipitación intensa.

Los sistemas de navegación vehicular actuales, como Google Maps o Waze, optimizan rutas considerando principalmente distancia y condiciones de tráfico en tiempo real. Sin embargo, estos sistemas no incorporan información sobre riesgos hidrometeorológicos ni probabilidades de falla de la infraestructura vial. Esta limitación expone a los usuarios a situaciones potencialmente peligrosas cuando las condiciones meteorológicas deterioran la transitabilidad de ciertas vías.

El presente trabajo aborda esta problemática mediante el desarrollo de un sistema de ruteo inteligente que integra múltiples fuentes de datos geográficos para calcular rutas que minimicen simultáneamente la distancia recorrida y la exposición a riesgos de inundación. El sistema propuesto representa una contribución original en varios aspectos: (1) integración de fuentes de datos gubernamentales chilenas con OpenStreetMap, (2) modelo de probabilidad de falla basado en proximidad a múltiples tipos de amenazas, (3) comparación sistemática de cuatro algoritmos de ruteo con diferentes características de optimalidad y eficiencia, y (4) plataforma web interactiva para visualización y simulación de escenarios de falla.

El resto del artículo se organiza de la siguiente manera: la Sección II presenta el estado del arte en sistemas de ruteo resiliente y modelamiento de riesgos de inundación. La

Sección III describe la problemática específica abordada con evidencia de estudios relevantes. La Sección IV presenta la hipótesis de investigación. La Sección V detalla los objetivos del proyecto. La Sección VI describe la metodología de desarrollo incluyendo arquitectura, fuentes de datos, modelo de probabilidad y algoritmos implementados. La Sección VII presenta los resultados experimentales y análisis comparativo. Finalmente, la Sección VIII ofrece conclusiones y direcciones de trabajo futuro.

A. Motivación y Contexto

La motivación principal de este trabajo surge de la observación de que los sistemas de navegación actuales, ampliamente utilizados por millones de conductores diariamente, no consideran adecuadamente los riesgos asociados a condiciones meteorológicas adversas. Durante eventos de precipitación intensa, es común observar vehículos atrapados en pasos bajo nivel anegados o en zonas cercanas a cauces desbordados, situaciones que podrían haberse evitado con información adecuada.

En Santiago de Chile, esta problemática se agrava por varios factores geográficos y urbanos:

- **Topografía compleja:** La ciudad se ubica en un valle rodeado por la Cordillera de los Andes al oriente y la Cordillera de la Costa al poniente, lo que canaliza las escorrentías hacia el fondo del valle.
- **Quebradas andinas:** Múltiples quebradas descienden desde la precordillera atravesando zonas densamente pobladas, incluyendo Macul, Lo Canas, San Ramon y Rabuco.
- **Cauces urbanos:** El río Mapocho y el Zanjón de la Aguada atraviesan la ciudad de oriente a poniente, con múltiples cruces viales vulnerables.
- **Impermeabilización:** El crecimiento urbano ha reducido drásticamente las áreas permeables, aumentando el volumen y velocidad de escorrentías superficiales.
- **Infraestructura de drenaje insuficiente:** El sistema de alcantarillado pluvial no fue diseñado para los volúmenes actuales de escorrentía.

Estos factores combinados generan situaciones recurrentes de inundación durante la temporada de lluvias (mayo-agosto), afectando la movilidad de cientos de miles de personas y causando pérdidas económicas significativas.

B. Contribuciones del Trabajo

Las principales contribuciones de este trabajo son:

- 1) **Integración de datos heterogéneos:** Se desarrolló un pipeline ETL que integra datos de OpenStreetMap con fuentes gubernamentales chilenas (DGA, SERNA-GEOMIN) y datos ambientales (SRTM, CHIRPS), creando una base de datos unificada para análisis de riesgo.
- 2) **Modelo de probabilidad de falla:** Se propone un modelo matemático que calcula la probabilidad de falla de cada segmento vial basado en su proximidad a múltiples tipos de amenazas, utilizando funciones de decaimiento exponencial con pesos calibrados.

- 3) **Comparación sistemática de algoritmos:** Se implementaron y compararon cuatro algoritmos de ruteo con diferentes características de optimalidad y eficiencia, proporcionando guías para su aplicación según el contexto.
- 4) **Plataforma web interactiva:** Se desarrolló una herramienta de visualización que permite a usuarios y planificadores explorar rutas alternativas, comparar métricas y simular escenarios de falla.
- 5) **Validación empírica:** Se realizaron experimentos sistemáticos que demuestran la efectividad de los algoritmos resilientes en reducir la exposición a riesgo con incrementos moderados en distancia.

II. ESTADO DEL ARTE

A. Resiliencia en Sistemas de Transporte

El concepto de resiliencia en infraestructura de transporte ha evolucionado significativamente en las últimas dos décadas. Murray-Tuite (Murray-Tuite & Mahmassani, 2006) propuso una de las primeras definiciones formales, caracterizando la resiliencia como la capacidad de un sistema de transporte para mantener niveles aceptables de servicio ante perturbaciones. Esta definición enfatiza tanto la robustez (capacidad de resistir perturbaciones) como la recuperabilidad (capacidad de restaurar funcionalidad).

Mattsson y Jenelius (Mattsson & Jenelius, 2015) extendieron este marco conceptual incorporando la dimensión geográfica de la vulnerabilidad. Su trabajo identifica que ciertos enlaces de una red de transporte son críticos no por su capacidad intrínseca, sino por su ubicación topológica: puentes, túneles y pasos a desnivel frecuentemente constituyen cuellos de botella cuya falla tiene impactos desproporcionados en la conectividad global de la red.

En el contexto latinoamericano, Garrido y Mahmassani (Garrido & Mahmassani, 2000) analizaron la vulnerabilidad de redes de transporte urbano en ciudades con alta variabilidad climática, proponiendo métricas de accesibilidad que consideran la probabilidad de congestión y cierre de vías.

B. Modelamiento de Inundaciones Urbanas

El modelamiento del impacto de inundaciones en infraestructura de transporte requiere integrar conocimientos de hidrología, ingeniería de transporte y gestión de riesgos. Pregnolato et al. (Pregnolato et al., 2017) establecieron relaciones empíricas entre profundidad de agua en calzadas y velocidad vehicular segura, demostrando que profundidades superiores a 30 cm comprometen severamente la operación de vehículos convencionales.

Suarez et al. (Suárez et al., 2005) cuantificaron el impacto económico de inundaciones en redes de transporte, estimando que eventos de inundación moderada pueden reducir la capacidad efectiva de la red en hasta un 40%.

En Chile, Garreaud et al. (Garreaud et al., 2020) documentaron la variabilidad climática en la zona central y su relación con eventos de precipitación extrema. Su análisis

revela patrones de variabilidad interanual que dificultan la predicción pero informan estrategias de gestión de riesgo.

C. Algoritmos de Optimización para Ruteo

El algoritmo de Dijkstra (Dijkstra, 1959), publicado en 1959, sigue siendo la base de la mayoría de sistemas de navegación modernos debido a su eficiencia ($O((V+E) \log V)$ con colas de prioridad) y garantía de optimalidad para costos no negativos.

Para problemas con múltiples objetivos, la programación lineal entera mixta (MILP) ofrece garantías de optimalidad global. Wolsey (Wolsey, 1998) proporciona una referencia comprehensiva sobre técnicas de MILP incluyendo métodos de ramificación y acotamiento.

El algoritmo A* (Hart et al., 1968) extiende Dijkstra incorporando una heurística que estima el costo restante hacia el destino. Cova y Johnson (Cova & Johnson, 2003) aplicaron A* modificado al problema de evacuación de emergencias.

D. Sistemas de Información Geográfica

PostGIS, la extensión espacial de PostgreSQL, proporciona un entorno robusto para almacenar y analizar datos geográficos. La integración con pgRouting permite ejecutar algoritmos de ruteo directamente sobre datos espaciales.

OpenStreetMap (OSM) se ha consolidado como la fuente de datos geográficos colaborativos más completa. Haklay (Haklay, 2010) analizó la calidad de datos OSM, encontrando que el 80% de las carreteras principales están mapeadas con precisión submétrica.

E. Justificación de Tecnologías Seleccionadas

La selección del stack tecnológico para este proyecto requirió un análisis comparativo de las alternativas disponibles, considerando criterios de funcionalidad, costo, escalabilidad y capacidades específicas para análisis espacial.

1) *OpenStreetMap vs. Google Maps API*: Se optó por OpenStreetMap como fuente de datos de infraestructura vial por las siguientes razones:

- 1) **Acceso a topología del grafo**: OSM proporciona acceso directo a la estructura de nodos y aristas de la red vial, permitiendo cálculos personalizados de ruteo. Google Maps API solo expone endpoints de alto nivel que devuelven rutas precalculadas sin acceso a la estructura subyacente del grafo.
- 2) **Ausencia de costos por consulta**: OSM es completamente gratuito y de código abierto, mientras que Google Maps API cobra por consulta después de un límite mensual (USD 200 de crédito gratuito). Para un sistema de investigación que requiere miles de consultas durante desarrollo y validación, esto representa un ahorro significativo.
- 3) **Flexibilidad de procesamiento**: Los datos OSM pueden descargarse completamente y procesarse localmente, permitiendo agregar atributos personalizados (como probabilidades de falla) directamente en la base de datos.

Con Google Maps, esto requeriría almacenar datos duplicados y sincronizar constantemente.

- 4) **Calidad comparable**: Según Haklay (2010), la calidad posicional de OSM en áreas urbanas es comparable a fuentes comerciales, con el 80% de las vías principales mapeadas con precisión submétrica.

2) *PostgreSQL/PostGIS vs. MySQL/MariaDB*: La elección de PostgreSQL con PostGIS sobre MySQL/MariaDB con extensiones espaciales se fundamenta en:

- 1) **Madurez de extensiones espaciales**: PostGIS es la extensión espacial de código abierto más completa y utilizada, con más de 20 años de desarrollo activo. Implementa el estándar OGC Simple Features completo, mientras que las capacidades espaciales de MySQL son más limitadas y no conformes con el estándar completo.
- 2) **Integración con pgRouting**: pgRouting proporciona más de 20 algoritmos de ruteo optimizados (Dijkstra, A*, TRSP, traveling salesman, etc.) que operan directamente sobre geometrías PostGIS. No existe un equivalente comparable para MySQL.
- 3) **Índices espaciales avanzados**: PostGIS utiliza índices GiST (Generalized Search Tree) que son significativamente más eficientes para consultas espaciales complejas que los índices R-tree de MySQL.
- 4) **Funciones de análisis**: PostGIS ofrece más de 300 funciones espaciales incluyendo ST_Distance, ST_Buffer, ST_Intersects, y análisis de redes, comparado con aproximadamente 50 funciones en MySQL.

3) *CPLEX vs. Solvers de Código Abierto*: Para la optimización MILP se seleccionó IBM CPLEX sobre alternativas de código abierto como GLPK, CBC o SCIP debido a:

- 1) **Rendimiento**: CPLEX es consistentemente 10-100x más rápido que solvers de código abierto en problemas de tamaño medio a grande, según benchmarks de la comunidad de optimización. Para redes de más de 30,000 aristas, esta diferencia es crítica.
- 2) **Licencia académica gratuita**: IBM proporciona licencias gratuitas para uso académico, eliminando la barrera de costo para investigación.
- 3) **Biblioteca docplex**: La API Python de CPLEX (docplex) ofrece una sintaxis declarativa moderna que simplifica significativamente la formulación de modelos comparado con las APIs de bajo nivel de solvers open source.

F. Modelos de Probabilidad de Falla: Comparativa

La literatura presenta tres enfoques principales para modelar la probabilidad de falla de infraestructura basada en proximidad a amenazas:

1) *Modelo Binario*: El enfoque más simple asigna probabilidad $p = 1$ si la distancia a la amenaza es menor que un umbral d_{max} , y $p = 0$ en caso contrario:

$$p_{binario}(d) = \begin{cases} 1 & \text{si } d < d_{max} \\ 0 & \text{si } d \geq d_{max} \end{cases} \quad (1)$$

Ventajas: Simplicidad computacional y facilidad de interpretación.

Desventajas: No captura la gradualidad del riesgo; una arista a 149m de un río tiene el mismo riesgo que una a 1m.

2) *Modelo Lineal:* Asigna probabilidad proporcional inversa a la distancia:

$$p_{lineal}(d) = \max\left(0, 1 - \frac{d}{d_{max}}\right) \quad (2)$$

Ventajas: Captura gradualidad y es fácil de interpretar.

Desventajas: Asume relación lineal entre distancia y riesgo, lo cual no corresponde con la física de inundaciones donde el riesgo decrece más rápidamente cerca de la fuente.

3) *Modelo Exponencial (Seleccionado):* Utiliza decaimiento exponencial con radio de influencia característico r :

$$p_{exp}(d) = \exp\left(-\frac{d}{r}\right) \quad (3)$$

Ventajas:

- Captura el comportamiento físico de propagación de inundaciones, donde la profundidad del agua decrece exponencialmente con la distancia al cauce según modelos hidrodinámicos (Pregolato et al., 2017).
- El parámetro r tiene interpretación física: representa la distancia a la cual el riesgo se reduce al 37% ($1/e$) del valor máximo.
- Permite combinar múltiples fuentes de amenaza mediante suma ponderada manteniendo probabilidades en el rango $[0,1]$.
- Diferenciabilidad continua facilita optimización gradiente-basada si se requiere en el futuro.

Justificación de selección: El modelo exponencial fue seleccionado porque representa más fielmente la física de las inundaciones. Estudios empíricos de Pregolato et al. (Pregolato et al., 2017) demuestran que la profundidad del agua en calles adyacentes a cauces desbordados sigue un patrón de decaimiento aproximadamente exponencial con la distancia. Además, este modelo es consistente con la teoría de difusión de fluidos en superficies urbanas impermeables.

G. Métricas de Resiliencia

Bruneau et al. (Bruneau et al., 2003) propusieron el marco “4R” que caracteriza la resiliencia en términos de Robustez, Redundancia, Recursividad y Rapidez. Para este trabajo, adoptamos métricas operacionales: distancia total, riesgo acumulado, tiempo de cómputo, y disponibilidad bajo fallas.

H. Trabajos Relacionados en Chile

En el contexto chileno, varios trabajos han abordado la gestión de riesgos de desastres naturales con enfoque geográfico:

- El Centro Nacional de Investigación para la Gestión Integrada de Desastres Naturales (CIGIDEN) ha desarrollado modelos de vulnerabilidad sísmica y de tsunami para

ciudades costeras chilenas, proporcionando metodologías transferibles al contexto de inundaciones.

- La Dirección General de Aguas (DGA) mantiene un sistema de alerta temprana para crecidas de ríos, con estaciones de monitoreo en tiempo real. Sin embargo, esta información no está integrada con sistemas de navegación vehicular.
- El Ministerio de Vivienda y Urbanismo (MINVU) ha desarrollado mapas de riesgo de inundación para planificación urbana, pero estos no están disponibles en formatos interoperables con sistemas de transporte.
- Investigadores de la Universidad de Chile han propuesto modelos de evacuación ante aluviones en la zona precordillerana, pero sin integración con sistemas de ruteo vehicular convencional.

El presente trabajo busca cerrar la brecha entre estos esfuerzos de gestión de riesgo y los sistemas de navegación vehicular de uso cotidiano.

I. Brechas Identificadas

A partir de la revisión del estado del arte, se identifican las siguientes brechas que este trabajo busca abordar:

- 1) **Falta de integración:** Los datos de riesgo existen pero no están integrados con sistemas de ruteo accesibles al público general.
- 2) **Enfoque reactivo:** Los sistemas actuales responden a eventos ya ocurridos en lugar de anticipar riesgos basados en probabilidades.
- 3) **Monobjetivo:** La mayoría de algoritmos de ruteo optimizan un solo criterio (distancia o tiempo), sin considerar riesgo.
- 4) **Falta de comparación:** No existen estudios comparativos sistemáticos de diferentes algoritmos de ruteo resiliente en el contexto latinoamericano.
- 5) **Ausencia de herramientas:** No hay plataformas interactivas que permitan a usuarios evaluar trade-offs entre distancia y riesgo.

III. PROBLEMÁTICA

La Región Metropolitana de Santiago enfrenta una problemática multidimensional relacionada con inundaciones urbanas y su impacto en la movilidad. Esta sección documenta la evidencia que sustenta la relevancia del problema.

A. Estudio 1: Cambio Climático e Intensificación de Precipitaciones

El Panel Intergubernamental sobre Cambio Climático (IPCC) ha documentado extensivamente los cambios en patrones de precipitación (IPCC, 2021). El Sexto Informe indica que:

- La intensidad de precipitaciones extremas ha aumentado globalmente desde 1950 con alta confianza estadística.
- En América del Sur, se observa un aumento del 15-20% en intensidad de eventos extremos durante las últimas tres décadas.

- Las proyecciones para mediados de siglo indican incrementos adicionales del 10-30% bajo escenarios de emisión moderados.
- Las áreas urbanas experimentan amplificación debido al fenómeno de “isla de calor” y la impermeabilización.

B. Estudio 2: Vulnerabilidad Geológica de Santiago

SERNAGEOMIN ha realizado estudios detallados de peligros geológicos en la Región Metropolitana (SERNAGEOMIN, 2020):

- Identificación de 47 zonas de alto riesgo de inundación concentradas en:
 - Riberas del río Mapocho y afluentes
 - Cauce del Zanjón de la Aguada
 - Quebradas precordilleranas (Macul, Lo Canas, San Ramon)
 - Áreas de baja pendiente en comunas del sector poniente
- Registro histórico de 23 eventos significativos en la última década.
- El 12% de la red vial principal atraviesa zonas de riesgo moderado a alto.

C. Estudio 3: Impacto en Infraestructura de Transporte

El Ministerio de Obras Públicas (MOP) mantiene registros de incidentes (MOP, 2019):

- 23 pasos bajo nivel con antecedentes de anegamiento incluyendo:
 - Paso bajo nivel Santa María (3 cierres en 2019)
 - Paso bajo nivel Lo Ovalle (anegamiento crónico)
 - Paso bajo nivel Departamental (hasta 4 horas de cierre)
- Tiempos promedio de cierre de 2-6 horas durante precipitación intensa.
- Impacto en congestión estimado en 30-45% de aumento en tiempos de viaje.
- 127 accidentes vehiculares relacionados con inundación en 2019.

D. Limitaciones de Sistemas Actuales

Los sistemas de navegación dominantes presentan limitaciones:

- 1) **Reactividad:** Solo incorporan información después de reportes de usuarios.
- 2) **Sin modelamiento de riesgo:** Optimizan distancia o tiempo, no probabilidades de falla.
- 3) **Falta de integración local:** Fuentes gubernamentales chilenas no están integradas.
- 4) **Comportamiento de manada:** Redirección simultánea genera nueva congestión.

IV. HIPÓTESIS

“Es posible mejorar significativamente la resiliencia del transporte urbano en Santiago de Chile mediante un sistema de ruteo inteligente basado en SIG que integre datos de

infraestructura vial con fuentes de amenazas hidrometeorológicas, calcule probabilidades de falla dinámicas, e implemente algoritmos que consideren simultáneamente distancia y riesgo. El sistema deberá reducir la exposición a riesgo en al menos 40% respecto a rutas tradicionales, con incrementos en distancia no superiores al 15%.”

V. OBJETIVOS

A. Objetivo General

Diseñar, implementar y evaluar un sistema de ruteo resiliente para la red vial de Santiago que calcule rutas óptimas considerando distancia y riesgo de inundación.

B. Objetivos Específicos

- 1) Desarrollar pipeline ETL para extraer red vial de OpenStreetMap.
- 2) Integrar metadata ambiental (elevación, precipitación, cobertura de suelo).
- 3) Incorporar datos de amenazas (DGA, SERNAGEOMIN, reportes ciudadanos).
- 4) Diseñar modelo de probabilidad de falla por proximidad a amenazas.
- 5) Implementar cuatro algoritmos: Dijkstra baseline, Dijkstra resiliente, MILP/CPLEX, A*.
- 6) Desarrollar interfaz web interactiva con visualización y simulación.
- 7) Validar mediante comparación de métricas y simulación de fallas.

VI. METODOLOGÍA

A. Arquitectura del Sistema

El sistema se estructura en tres capas siguiendo arquitectura de tres niveles. La Figura 1 presenta el diagrama de arquitectura completo.

B. Pipeline ETL

El proceso de Extracción, Transformación y Carga (ETL) fue implementado en Python 3.11 utilizando las bibliotecas GeoPandas 0.14, Shapely 2.0, y Requests. El pipeline se organiza en tres fases principales, diseñadas para ser completamente replicables.

Fase 1: Extracción de Infraestructura Vial

La red vial se extrae de OpenStreetMap mediante la API Overpass con la siguiente consulta estructurada:

```
[out:json][timeout:300];
area["name"="Santiago"]["admin_level"="8"]->.a;
(way(area.a)["highway"~"primary|secondary|
tertiary|residential|trunk"];
out geom;
```

La respuesta JSON (aproximadamente 45 MB) se procesa mediante el siguiente algoritmo:

- 1) **Parsing:** Se extraen todos los elementos way con sus nodos y coordenadas.
- 2) **Construcción del grafo:** Para cada way, se crean aristas entre nodos consecutivos. Los nodos compartidos entre múltiples ways se identifican como intersecciones.




Fig. 1. Arquitectura de tres capas del sistema de ruteo resiliente

- 3) **Filtrado:** Se excluyen tipos de vía no vehiculares: footway, cycleway, pedestrian, steps, path, service.
- 4) **Cálculo de longitud:** Se calcula la distancia geodésica en metros usando la fórmula de Haversine para cada arista.
- 5) **Generación de geometría:** Se crean objetos LineString de Shapely para cada arista.

Fase 2: Extracción de Amenazas

Las amenazas se obtienen de múltiples fuentes gubernamentales mediante APIs REST y archivos GeoJSON:

- **Estaciones DGA (94 puntos):** Se consulta la API del Ministerio de Medio Ambiente (`arclim.mma.gob.cl`) extrayendo coordenadas WGS84 y metadatos de estaciones fluviométricas activas en la Región Metropolitana. El proceso incluye filtrado por código de cuenca (057-Maipo) y validación de coordenadas.
- **Ríos y quebradas (58 segmentos):** Los cauces se obtienen del GeoPortal IDE Chile en formato Shapefile, reproyectados a EPSG:4326. Se aplica un buffer de 150 metros usando `ST_Buffer` para definir zonas de influencia, basándose en estudios de alcance lateral de inundaciones urbanas.
- **Pasos bajo nivel (20 puntos):** Lista curada manualmente a partir de registros del MOP, informes de prensa (2015-2024), y reportes de Bomberos de Chile. Cada punto incluye historial de cierres y profundidad máxima registrada.
- **Reportes ciudadanos (25 puntos):** Geocodificación de

reportes de inundación extraídos de Twitter/X, Waze, y medios locales usando la API de Nominatim con validación manual de coordenadas.

Fase 3: Cálculo de Probabilidades

El cálculo de probabilidades se ejecuta directamente en PostgreSQL para aprovechar los índices espaciales GiST:

```

UPDATE infra_aristas a SET p_fallo_arista = (
  SELECT LEAST(1.0, COALESCE(
    0.4 * (SELECT MAX(EXP(-ST_Distance(
      a.geom::geography, r.geom::geography)/500.0))
    FROM amenaza_rios r) +
    0.3 * (SELECT MAX(EXP(-ST_Distance(
      a.geom::geography, d.geom::geography)/1000.0))
    FROM amenaza_dga d) +
    0.2 * (SELECT MAX(EXP(-ST_Distance(
      a.geom::geography, p.geom::geography)/200.0))
    FROM amenaza_reportes_ciudadanos p), 0.0))
);
  
```

El tiempo de ejecución es aproximadamente 45 segundos para las 33,947 aristas, gracias a los índices espaciales. La función `LEAST(1.0, ...)` asegura que las probabilidades no excedan 1.0 cuando múltiples amenazas coinciden.

Replicabilidad: Todo el código ETL está disponible en el repositorio GitHub. Para replicar:

- 1) Ejecutar `python main.py` (genera archivos GeoJSON)
- 2) Ejecutar `python load_to_supabase.py` (carga a PostgreSQL)
- 3) Ejecutar `sql/setup_and_calculate_probabilities.sql`

La Figura 2 muestra el flujo del proceso ETL implementado.

C. Esquema de Base de Datos

El modelo de datos se implementó en PostgreSQL 15 con las extensiones PostGIS 3.3 para datos espaciales y pgRouting 3.4 para algoritmos de ruteo. El esquema completo se organiza en tres grupos de tablas: infraestructura, metadata y amenazas.




Fig. 2. Pipeline ETL para extracción y carga de datos

1) *Tablas de Infraestructura*: Las tablas principales del esquema incluyen *infra_nodos* (28,208 registros) para los nodos de la red e *infra_aristas* (33,947 registros) para las aristas, ambas con geometrias PostGIS e índices espaciales GiST para consultas eficientes. El esquema completo se presenta en el Apéndice A.

2) *Tablas de Amenazas*: Las amenazas se almacenan en tablas separadas según su fuente y tipo geométrico, incluyendo:

- *amenaza_dga*: Estaciones de monitoreo hidrológico (94 registros)
- *amenaza_ríos*: Zonas de inundación histórica con buffer de 150m (58 segmentos)
- *amenaza_pasos_bajo_nivel*: Pasos bajo nivel vulnerables (20 registros)
- *amenaza_reportes_ciudadanos*: Reportes de inundación geolocalizados (25 registros)

El detalle de las tablas de amenazas se presenta en el Apéndice A.

3) *Tablas de Simulación*: Para la simulación de fallas se utiliza una tabla temporal (*sim_fallas_activas*) que almacena el estado de cada arista, incluyendo identificadores de simulación, probabilidad de falla, valor aleatorio generado y estado de falla (ver Apéndice A).

D. Modelo de Probabilidad de Falla

La probabilidad de falla de cada arista e se calcula como:

$$p_e = \sum_{i=1}^n w_i \cdot f_i(d_{i,e}) \quad (4)$$

Con función de decaimiento exponencial:

$$f_i(d) = \exp\left(-\frac{d}{r_i}\right) \quad (5)$$

La Figura 3 ilustra el modelo de probabilidad.




Fig. 3. Modelo de combinación de factores para probabilidad de falla

TABLA I
PARÁMETROS DEL MODELO DE PROBABILIDAD

Factor	Peso	Radio	Fuente
Inundación histórica	0.40	500 m	SERNAGEOMIN
Proximidad DGA	0.30	1000 m	DGA Chile
Reportes ciudadanos	0.20	200 m	Crowdsourcing
Precipitación	0.10	1000 m	CHIRPS

E. Algoritmos Implementados

1) *Dijkstra Baseline*: El algoritmo de Dijkstra clásico se implementa utilizando la función *pgr_dijkstra* de *pgRouting*, que calcula la ruta de costo mínimo usando distancia como único criterio:

$$cost_e = length_e \quad (6)$$

La consulta SQL correspondiente se presenta en el Apéndice A.

Esta implementación filtra vías peatonales y ciclovías para asegurar que la ruta sea transitable por vehículos motorizados. El parámetro *directed := false* indica que la red es no dirigida, permitiendo circular en ambos sentidos por cada arista.

2) *Dijkstra Resiliente*: Incorpora la probabilidad de falla como penalización multiplicativa en el costo:

$$cost_e = length_e \cdot (1 + k \cdot p_e) \quad (7)$$

Donde k es el factor de penalización (default: 5.0). Este factor determina cuan agresivamente el algoritmo evita zonas de alto riesgo. La consulta SQL correspondiente se presenta en el Apéndice A.

El costo modificado tiene las siguientes propiedades:

- Si $p_e = 0$, el costo es simplemente la distancia
- Si $p_e = 1$ (falla segura), el costo se multiplica por $(1 + k)$
- Valores intermedios generan penalizaciones proporcionales

3) *MILP con CPLEX*: La formulación como problema de programación lineal entera mixta (MILP) permite obtener soluciones globalmente óptimas considerando simultáneamente distancia y riesgo. Se utiliza IBM CPLEX a través de la biblioteca *docplex* de Python.

Variables de decisión:

$$x_e \in \{0, 1\} \quad \forall e \in E \quad (8)$$

Donde $x_e = 1$ si la arista e pertenece a la ruta óptima.

Función objetivo:

$$\min \sum_{e \in E} x_e \cdot (length_e + \lambda \cdot length_e \cdot p_e) \quad (9)$$

El parámetro λ (lambda_risk) controla el trade-off entre distancia y riesgo. Valores típicos varían entre 1.0 y 10.0.

Restricciones de conservación de flujo:

$$\sum_{e \in \delta^+(v)} x_e - \sum_{e \in \delta^-(v)} x_e = b_v \quad \forall v \in V \quad (10)$$

Donde $b_v = 1$ si v es el origen, $b_v = -1$ si v es el destino, y $b_v = 0$ para nodos intermedios. Esta restricción asegura que el flujo que entra a cada nodo es igual al que sale, excepto en origen y destino.

Restricciones opcionales de riesgo máximo:

$$\sum_{e \in E} x_e \cdot p_e \leq max_risk \cdot \sum_{e \in E} x_e \quad (11)$$

Esta restricción limita el riesgo promedio de la ruta al valor max_risk .

Restricciones opcionales de distancia máxima:

$$\sum_{e \in E} x_e \cdot length_e \leq max_distance \quad (12)$$

Limita la distancia total de la ruta.

La implementación completa en Python usando la biblioteca docplex se presenta en el Apéndice A.

La complejidad computacional de MILP es NP-hard, pero CPLEX utiliza técnicas avanzadas como ramificación y acotamiento (branch and bound), planos de corte, y preprocesamiento que permiten resolver instancias de tamaño moderado en tiempos razonables.

4) *A* con Heurística de Riesgo*: El algoritmo A* extiende Dijkstra incorporando una heurística que estima el costo restante hacia el destino, lo que permite explorar menos nodos al priorizar direcciones prometedoras.

Función de evaluación:

$$f(n) = g(n) + h(n) \quad (13)$$

Donde:

- $g(n)$: Costo acumulado desde el origen hasta el nodo n
- $h(n)$: Estimación heurística del costo desde n hasta el destino

Función de costo $g(n)$:

$$g(n) = \sum_{e \in path(s,n)} length_e \cdot (1 + w_{risk} \cdot p_e) \quad (14)$$

El parámetro w_{risk} (risk_weight) controla la penalización por riesgo, análogo al factor k en Dijkstra resiliente.

Heurística admisible:

$$h(n) = w_h \cdot dist_{euclidiana}(n, target) \quad (15)$$

La distancia euclidiana es admisible (nunca sobreestima el costo real) ya que la distancia más corta entre dos puntos es

Baseline	Riesgo	Óptimo	Heurístico
Dijkstra	Resiliente	CPLEX	A*
cost = dist	cost = dist*(1+k*p)	MILP global	f = g + h

Fig. 4. Comparación de los cuatro algoritmos implementados

la línea recta. El factor w_h permite ajustar la agresividad de la heurística.

La implementación completa en Python se presenta en el Apéndice A.

La ventaja de A* sobre Dijkstra es que explora menos nodos cuando la heurística es informativa. En redes geográficas donde existe correlación entre distancia euclidiana y distancia en la red, A* puede ser significativamente más eficiente.

La Figura 4 compara los flujos de los cuatro algoritmos.

F. Interfaz Web

La interfaz de usuario se desarrolló utilizando Next.js 14 con React 18 y la biblioteca de mapas Leaflet para visualización geográfica interactiva. El diseño se estructuró en componentes modulares que permiten una experiencia de usuario fluida y responsiva.

1) Componentes Principales:

- **Mapa Interactivo:** Visualización basada en Leaflet con capas de OpenStreetMap como base cartográfica. Soporta zoom, pan, y geolocalización automática del usuario mediante GPS del navegador.
- **Panel de Selección:** Permite especificar origen y destino mediante tres métodos: (1) click directo en el mapa, (2) geocodificación por dirección usando Nominatim, (3) ingreso manual de coordenadas o ID de nodo.
- **Panel de Capas:** Checkboxes para activar/desactivar la visualización de amenazas (estaciones DGA, zonas de inundación histórica, reportes ciudadanos, pasos bajo nivel) y metadata (elevación, precipitación).
- **Panel de Rutas:** Toggle switches para mostrar/ocultar cada una de las cuatro rutas calculadas, con código de colores consistente (azul: baseline, verde: resiliente, morado: CPLEX, naranja: A*).
- **Tabla Comparativa:** Muestra métricas de distancia, riesgo acumulado, tiempo de cómputo y número de aristas para cada algoritmo, permitiendo comparación directa.
- **Simulador de Fallas:** Slider para seleccionar tasa de falla (0-100%) y botón para activar simulación, que marca aristas fallidas en rojo en el mapa.

2) *Endpoints de la API*: La API REST implementada expone los siguientes endpoints:

3) *Flujo de Interacción*: La Figura 5 ilustra el flujo típico de interacción del usuario con el sistema.

TABLA II
ENDPOINTS DE LA API DE RUTEO

Endpoint	Descripción
GET /api/route/baseline	Ruta más corta (Dijkstra)
GET /api/route/resilient	Ruta con costo resiliente
GET /api/route/optimize	Ruta óptima (CPLEX MILP)
GET /api/route/metaheuristic	Ruta A* con heurística
GET /api/route/compare	Ejecuta los 4 algoritmos
GET /api/geocode	Geocodificación de direcciones
POST /api/simulate-failures	Activa simulación de fallas
GET /api/layers/*	Capas de amenazas y metadata




Fig. 5. Flujo de interacción del usuario con el sistema

TABLA III
ESTADÍSTICAS DE LA RED VIAL CARGADA

Métrica	Valor
Nodos totales	28,208
Aristas totales	33,947
Cobertura geográfica	Región Metropolitana
Estaciones DGA	94
Segmentos de ríos	58
Pasos bajo nivel	20
Reportes ciudadanos	25
Líneas de código Python	5,408
Líneas de código TypeScript	5,922
Líneas de código SQL	1,341

TABLA IV
RESULTADOS SIN SIMULACIÓN DE FALLAS

Algoritmo	Dist.(m)	Riesgo	Tiempo(ms)	Éxito
Baseline	4,523	0.187	45	100%
Resiliente	4,891	0.092	52	100%
CPLEX	4,756	0.078	8,340	95%
A*	4,834	0.095	180	100%

VII. DESARROLLO Y RESULTADOS

A. Estadísticas del Sistema

B. Evaluación Comparativa Sin Fallas

Se ejecutaron los cuatro algoritmos para 50 pares origen-destino aleatorios.

TABLA V
RESULTADOS CON 10% DE FALLAS ACTIVAS

Algoritmo	Dist.(m)	Riesgo	Tiempo(ms)	Éxito
Baseline	4,687	0.201	48	89%
Resiliente	4,923	0.088	55	96%
CPLEX	4,812	0.075	9,120	94%
A*	4,889	0.091	195	95%

TABLA VI
RESULTADOS CON 30% DE FALLAS ACTIVAS

Algoritmo	Dist.(m)	Riesgo	Tiempo(ms)	Éxito
Baseline	5,234	0.245	52	67%
Resiliente	5,456	0.098	61	82%
CPLEX	5,312	0.082	12,450	85%
A*	5,398	0.101	245	81%

TABLA VII
RESULTADOS CON 50% DE FALLAS ACTIVAS

Algoritmo	Dist.(m)	Riesgo	Tiempo(ms)	Éxito
Baseline	6,123	0.312	58	34%
Resiliente	6,234	0.124	68	58%
CPLEX	6,087	0.098	18,670	62%
A*	6,189	0.118	320	56%

Disponibilidad (%)




Fig. 6. Disponibilidad de rutas vs. tasa de falla

C. Evaluación con Simulación de Fallas

Se simularon escenarios de falla activando aleatoriamente aristas con probabilidad proporcional a p_{falla} .

D. Análisis de Disponibilidad

La Figura 6 muestra la disponibilidad de rutas bajo diferentes tasas de falla.

E. Análisis de Tiempos de Cómputo

F. Casos de Estudio

Para validar el comportamiento del sistema en situaciones realistas, se seleccionaron tres pares origen-destino representativos de diferentes patrones de viaje en Santiago.

TABLA VIII
ESTADÍSTICAS DE TIEMPO DE CÓMPUTO (MS)

Algoritmo	Min	P25	Med	P95	Max
Baseline	23	35	45	89	156
Resiliente	28	42	52	98	178
CPLEX	1,234	4,567	8,340	45,230	120,000
A*	89	134	180	456	890

TABLA IX
RUTA PROVIDENCIA - LAS CONDES SIN FALLAS

Algoritmo	Dist.	Riesgo	Cruces Río	Tiempo
Baseline	6,234 m	0.234	2	78 ms
Resiliente	6,891 m	0.089	0	92 ms
CPLEX	6,756 m	0.078	0	5,230 ms
A*	6,834 m	0.092	0	340 ms

TABLA X
RUTA PROVIDENCIA - LAS CONDES CON 30% FALLAS

Algoritmo	Dist.	Riesgo	Ruta OK	Tiempo
Baseline	7,123 m	0.287	No	85 ms
Resiliente	7,234 m	0.095	Si	98 ms
CPLEX	7,112 m	0.082	Si	6,120 ms
A*	7,189 m	0.098	Si	380 ms

TABLA XI
RUTA SANTIAGO CENTRO - MAIPU SIN FALLAS

Algoritmo	Dist.	Riesgo	Pasos BN	Tiempo
Baseline	12,456 m	0.312	3	134 ms
Resiliente	13,234 m	0.134	1	156 ms
CPLEX	12,987 m	0.118	1	12,340 ms
A*	13,112 m	0.142	1	567 ms

1) *Caso 1: Providencia a Las Condes*: Este caso representa un viaje típico entre comunas del sector oriente, atravesando zonas cercanas al río Mapocho.

Observaciones: La ruta baseline cruza el río Mapocho dos veces, exponiéndose a zonas de alto riesgo. Los algoritmos resilientes evitan estos cruces mediante un rodeo por Av. Apoquindo, aumentando la distancia en aproximadamente 10% pero reduciendo el riesgo en 62-67%.

Observaciones: Con 30% de fallas activas, la ruta baseline queda bloqueada en el cruce con el río, mientras que las rutas resilientes permanecen transitables al haber evitado proactivamente esa zona.

2) *Caso 2: Santiago Centro a Maipu*: Este caso representa un viaje desde el centro hacia el sector poniente, atravesando el Zanjón de la Aguada y zonas de baja elevación.

Observaciones: La ruta baseline atraviesa tres pasos bajo nivel con historial de anegamiento. Las rutas resilientes reducen esto a un solo paso bajo nivel (el de menor riesgo), con incremento de distancia del 4-6%.

Observaciones: Los casos de estudio muestran que CPLEX logra la mejor disponibilidad al encontrar caminos alternativos optimizados globalmente. La Tabla XII resume la disponibil-

TABLA XII
RUTA SANTIAGO CENTRO - MAIPU CON 50% FALLAS

Algoritmo	Dist.	Riesgo	Ruta OK	Tiempo
Baseline	14,234 m	0.398	No	145 ms
Resiliente	14,567 m	0.156	Si	178 ms
CPLEX	14,123 m	0.134	Si	18,450 ms
A*	14,345 m	0.167	Si	890 ms

TABLA XIII
RESUMEN DE DISPONIBILIDAD POR CASO DE ESTUDIO

Caso	Fallas	Base	Res.	CPLEX	A*
Providencia-LasCondes	30%	71%	89%	92%	88%
Santiago-Maipu	30%	62%	84%	88%	82%
LaFlorida-Vitacura	30%	67%	86%	89%	84%
Promedio 30%	—	67%	86%	90%	85%

TABLA XIV
ESTIMACIÓN DE COSTOS POR VEHÍCULO ATRAPADO

Concepto	Costo Estimado (USD)
Dano al vehículo (promedio)	2,500
Grua y rescate	150
Tiempo perdido (3 horas, \$25/hora)	75
Estres y consecuencias de salud	50
Total por evento	2,775

idad observada en 100 simulaciones.

Los algoritmos resilientes mantienen 19-23 puntos porcentuales más de disponibilidad que el baseline en escenarios de falla moderada (30%).

G. Análisis de Impacto Económico

Para cuantificar el beneficio potencial de implementar rutas resilientes, se realizó un análisis económico considerando los costos asociados a vehículos atrapados en inundaciones:

Considerando las estadísticas del MOP que reportan aproximadamente 127 incidentes anuales relacionados con inundación en Santiago, el costo total estimado es de USD 352,425 anuales. Si un sistema de ruteo resiliente lograra prevenir el 50% de estos incidentes, el ahorro anual sería de aproximadamente USD 176,000.

Adicionalmente, los tiempos de viaje perdidos por congestión causada por cierres de vías tienen un costo significativo. Estimando que un cierre de vía afecta a 5,000 vehículos con un retraso promedio de 20 minutos y un valor del tiempo de USD 15/hora, cada cierre tiene un costo social de USD 25,000. Con 23 pasos bajo nivel que experimentan cierres múltiples al año, el costo total podría superar USD 1.5 millones anuales.

H. Reducción de Riesgo

El “ratio” indica reducción de riesgo por punto porcentual de aumento en distancia.

I. Validación de Hipótesis

- 1) **Reducción de riesgo $\geq 40\%$:** **Cumplido.** Todos los algoritmos resilientes reducen el riesgo en más del 49%.

TABLA XV
REDUCCIÓN DE RIESGO RESPECTO A BASELINE

Algoritmo	Red. Riesgo	Aum. Dist.	Ratio
Resiliente	50.8%	8.1%	6.3
CPLEX	58.3%	5.2%	11.2
A*	49.2%	6.9%	7.1

- 2) **Incremento de distancia $\leq 15\%$:** **Cumplido.** Máximo incremento observado: 10.5%.
- 3) **Tiempos interactivos:** **Parcial.** Dijkstra y A* cumplen; CPLEX requiere optimización.

La hipótesis se considera **validada**.

J. Discusion de Resultados

1) *Trade-off Distancia vs. Riesgo:* Los resultados revelan un trade-off favorable entre distancia adicional recorrida y reducción de riesgo. En promedio, por cada punto porcentual de incremento en distancia, los algoritmos resilientes logran reducir el riesgo en 6-11 puntos porcentuales. Este ratio sugiere que el costo marginal de evitar zonas de riesgo es significativamente menor que el beneficio obtenido.

La relación no es lineal: las primeras desviaciones de la ruta óptima en distancia generan las mayores reducciones de riesgo, mientras que desviaciones adicionales muestran rendimientos decrecientes. Esto justifica la elección de factores de penalización moderados ($k = 5.0$) en lugar de valores extremos.

2) *Comportamiento bajo Fallas:* El análisis de escenarios de falla revela diferencias significativas en la robustez de los algoritmos:

- **Baseline:** Experimenta degradación rápida porque sus rutas atraviesan zonas de alto riesgo que tienen mayor probabilidad de falla. Con 30% de fallas activas, solo el 67% de las rutas permanecen transitables.
- **Resiliente:** Mantiene alta disponibilidad (82% con 30% de fallas) porque sus rutas evitan proactivamente las zonas de mayor probabilidad de falla.
- **CPLEX:** Logra la mejor disponibilidad (85%) debido a su optimización global que considera explícitamente la probabilidad de falla como parte de la función objetivo.
- **A*:** Comportamiento similar al resiliente (81%) con tiempos de cómputo intermedios, representando un buen compromiso para aplicaciones en tiempo real.

3) *Complejidad Computacional:* El análisis de tiempos de cómputo revela una clara jerarquía:

- 1) Dijkstra (baseline y resiliente): $O((V + E) \log V)$, tiempos en milisegundos. Adecuado para respuesta interactiva.
- 2) A*: Similar complejidad asintótica pero con constantes mayores debido al cálculo de heurística. Tiempos en centenas de milisegundos.
- 3) CPLEX: Complejidad exponencial en el peor caso (NP-hard). Tiempos de segundos a minutos dependiendo del tamaño de la subred considerada.

TABLA XVI
TIEMPOS DE CPLEX SEGÚN DISTANCIA ORIGEN-DESTINO

Distancia O-D	Aristas subred	Tiempo	Gap
< 5 km	~2,000	1.2 s	0%
5-10 km	~5,000	8.3 s	0%
10-15 km	~10,000	23.4 s	0.1%
> 15 km	~15,000	45+ s	0.5%

Para aplicaciones prácticas, se recomienda usar Dijkstra resiliente o A* para respuesta inmediata, reservando CPLEX para planificación anticipada donde el tiempo no es crítico.

4) *Análisis de Trade-offs de CPLEX:* La decisión de cuándo utilizar CPLEX requiere un análisis cuidadoso del trade-off entre calidad de solución y tiempo de cómputo. Los resultados experimentales permiten cuantificar este trade-off:

Mejora marginal en calidad: CPLEX logra una reducción de riesgo promedio de 58.3% comparado con 50.8% de Dijkstra resiliente, una mejora de 7.5 puntos porcentuales. Sin embargo, esta mejora viene con un incremento de tiempo de cómputo de 160x (8,340 ms vs. 52 ms en promedio).

Análisis costo-beneficio: Si definimos la “eficiencia de reducción de riesgo” como:

$$\eta = \frac{\Delta_{riesgo}}{\Delta_{tiempo}} = \frac{reduccion_riesgo}{tiempo_cmputo} \quad (16)$$

Entonces:

- Dijkstra resiliente: $\eta_{res} = 50.8\% / 0.052s = 977\%/s$
- CPLEX: $\eta_{cplex} = 58.3\% / 8.34s = 7\%/s$

Esta diferencia de dos órdenes de magnitud en eficiencia sugiere que CPLEX solo se justifica cuando:

- 1) La mejora marginal del 7.5% en reducción de riesgo tiene valor significativo (e.g., transporte de mercancías peligrosas, ambulancias).
- 2) El tiempo de planificación no es crítico (rutas precalculadas).
- 3) Se dispone de recursos computacionales dedicados.

Escalabilidad de CPLEX: Los tiempos de cómputo de CPLEX muestran alta variabilidad dependiendo de la estructura del problema:

Para distancias largas (>15 km), CPLEX frecuentemente alcanza el límite de tiempo (60 segundos) antes de garantizar optimalidad, retornando soluciones con gap de optimalidad de 0.5-1%. En estos casos, la ventaja teórica de optimalidad global se diluye.

Recomendación práctica: Basándose en este análisis, se propone un esquema híbrido:

- 1) Para consultas interactivas: usar Dijkstra resiliente (respuesta <100 ms).
- 2) Para rutas críticas con tiempo disponible: usar CPLEX con timeout de 30 segundos.
- 3) Para planificación offline: usar CPLEX sin límite de tiempo para generar catálogo de rutas óptimas entre puntos frecuentes.

TABLA XVII
SENSIBILIDAD AL FACTOR DE PENALIZACIÓN K

k	Red. Riesgo	Aum. Dist.	Desv. Ruta
1.0	18.2%	2.1%	Mínima
3.0	38.5%	5.4%	Moderada
5.0	50.8%	8.1%	Significativa
10.0	62.3%	14.7%	Alta

5) *Comparación Cualitativa de Rutas:* Más allá de las métricas numéricas, las rutas generadas por cada algoritmo muestran patrones geográficos distintivos que merecen análisis cualitativo:

Rutas Baseline: Siguen un patrón de “línea recta aproximada”, priorizando arterias principales (autopistas, avenidas) que frecuentemente cruzan ríos y quebradas en puntos de menor elevación. Este comportamiento es esperado dado que estas vías fueron diseñadas para minimizar distancias.

Rutas Resilientes: Exhiben “rodeos preventivos” alrededor de zonas de riesgo. En el caso Santiago Centro-Maipú, la ruta resiliente evita tres pasos bajo nivel usando Av. Departamental en superficie, aumentando distancia pero eliminando exposición a anegamiento.

Rutas CPLEX: Muestran el comportamiento más “inteligente”, identificando atajos locales que balancean riesgo y distancia. Por ejemplo, en el caso La Florida-Vitacura, CPLEX encuentra una ruta que cruza la quebrada Macul por un único punto (puente elevado) en lugar del rodeo completo que sugiere Dijkstra resiliente.

Rutas A*: Comportamiento intermedio, tendiendo a seguir la dirección general hacia el destino pero evitando amenazas mayores. La heurística euclidiana puede causar suboptimalidad cuando la ruta óptima requiere inicialmente alejarse del destino.

6) *Sensibilidad a Parámetros:* Se evaluaron diferentes valores del factor de penalización k :

El valor $k = 5.0$ representa un punto de equilibrio donde se logra reducción sustancial de riesgo (>50%) sin desviaciones excesivas en distancia (<10%).

7) *Limitaciones del Modelo de Probabilidad:* El modelo de probabilidad basado en proximidad presenta limitaciones inherentes:

- 1) **Asunción de independencia:** Las probabilidades de falla se modelan como independientes, cuando en realidad las fallas pueden estar correlacionadas espacial y temporalmente (una tormenta afecta múltiples zonas simultáneamente).
- 2) **Pesos estáticos:** Los pesos asignados a cada factor ($w_1 = 0.4$, $w_2 = 0.3$, etc.) fueron calibrados empíricamente y podrían no ser óptimos para todas las condiciones.
- 3) **Radio de influencia uniforme:** Se asume el mismo radio de influencia para todas las amenazas de un tipo, cuando en realidad podría variar según características locales.

- 4) **Ausencia de datos históricos:** No se dispone de datos de verificación histórica de rutas fallidas para validar las probabilidades estimadas.

VIII. CONCLUSIONES Y TRABAJO FUTURO

A. Conclusiones

Este trabajo ha presentado el diseño, implementación y evaluación de un sistema de ruteo resiliente para la red vial de Santiago de Chile, con enfoque en la mitigación de riesgos asociados a inundaciones urbanas. Las principales conclusiones derivadas del estudio son:

- 1) **Validación de la hipótesis:** Se demostró que es factible reducir la exposición a riesgo de inundación en más del 50% mediante algoritmos de ruteo que consideren probabilidades de falla, con incrementos de distancia consistentemente menores al 10%. Este resultado valida la hipótesis central del trabajo y demuestra que el trade-off entre distancia y seguridad es favorable para los usuarios.
- 2) **Comparación de algoritmos:** El análisis comparativo de los cuatro algoritmos implementados revela diferentes fortalezas según el contexto de uso:
 - **Dijkstra baseline:** Útil como referencia y para situaciones donde el riesgo no es relevante (días sin lluvia).
 - **Dijkstra resiliente:** Ofrece el mejor balance entre simplicidad de implementación y efectividad, con tiempos de cómputo en milisegundos. Recomendado para aplicaciones en tiempo real.
 - **CPLEX MILP:** Proporciona optimalidad global garantizada pero con tiempos de cómputo significativamente mayores (segundos a minutos). Recomendado para planificación anticipada o cálculo offline de rutas.
 - **A* con heurística de riesgo:** Representa un compromiso entre calidad de solución y velocidad, siendo más rápido que CPLEX pero potencialmente subóptimo. Adecuado para aplicaciones interactivas donde se requiere respuesta rápida pero la optimalidad estricta no es crítica.
- 3) **Escalabilidad:** El sistema demostró capacidad para procesar redes de más de 28,000 nodos y 33,000 aristas con tiempos de respuesta aceptables para uso interactivo (menores a 1 segundo para Dijkstra y A*, menores a 30 segundos para CPLEX en la mayoría de casos).
- 4) **Robustez ante fallas:** Los experimentos de simulación demostraron que los algoritmos resilientes mantienen significativamente mayor disponibilidad bajo escenarios de falla. Específicamente, con 30% de aristas fallidas, los algoritmos resilientes lograron 81-85% de disponibilidad comparado con solo 67% del baseline. Esta diferencia de 14-18 puntos porcentuales representa una mejora sustancial en la confiabilidad del sistema de transporte.
- 5) **Integración de datos:** La metodología desarrollada para integrar fuentes heterogéneas (OSM, DGA, SERNA-GEOMIN, datos ambientales) en un modelo unificado

de probabilidad de falla es transferible a otros contextos geográficos y tipos de amenazas.

- 6) **Utilidad práctica:** La plataforma web desarrollada proporciona una herramienta concreta que puede ser utilizada por ciudadanos, planificadores urbanos y servicios de emergencia para evaluar rutas alternativas durante eventos de precipitación.

B. Limitaciones

A pesar de los resultados positivos obtenidos, el estudio presenta varias limitaciones que deben ser consideradas al interpretar los resultados y que representan oportunidades para trabajo futuro:

- 1) **Calibración empírica de parámetros:** Los pesos del modelo de probabilidad ($w_1 = 0.4$, $w_2 = 0.3$, $w_3 = 0.2$, $w_4 = 0.1$) y los radios de influencia fueron calibrados empíricamente basándose en juicio experto y revisión de literatura. Una calibración más rigurosa requeriría datos históricos de fallas reales de la red vial durante eventos de inundación, los cuales no estaban disponibles para este estudio.
- 2) **Modelo estático:** El modelo actual calcula probabilidades de falla como valores fijos, sin considerar variaciones temporales. En la realidad, la probabilidad de falla varía según:
 - Hora del día (escorrentías se acumulan durante el día)
 - Precipitación acumulada en horas previas
 - Estado de saturación del suelo
 - Pronóstico meteorológico a corto plazoUn modelo dinámico que incorpore estas variables proporcionaría estimaciones más precisas.
- 3) **Validación geográfica limitada:** El sistema fue desarrollado y validado únicamente para la Región Metropolitana de Santiago. Si bien la metodología es transferible, los parámetros específicos (radios de influencia, pesos de amenazas) podrían requerir ajustes para otras ciudades con diferentes características topográficas e hidrológicas.
- 4) **Ausencia de evaluación con usuarios:** No se realizó una evaluación de usabilidad con usuarios reales del sistema. Sería valioso conocer:
 - Si los usuarios están dispuestos a aceptar rutas más largas a cambio de menor riesgo
 - Como prefieren que se presente la información de riesgo
 - Que nivel de confianza tienen en las recomendaciones del sistema

- 5) **Validación con eventos reales:** La validación se realizó mediante simulación de fallas basada en las probabilidades calculadas. Una validación más robusta requeriría comparar las predicciones del modelo con fallas reales observadas durante eventos de precipitación.
- 6) **Datos de amenazas incompletos:** Algunas fuentes de amenaza no pudieron ser incorporadas por falta de datos disponibles, incluyendo:

- Historial de anegamiento de calles específicas
- Estado de mantenimiento del sistema de alcantarillado
- Obras en construcción que pueden afectar el drenaje

C. Trabajo Futuro

- 1) **Integración en tiempo real con APIs de DGA:** Implementar conexión directa con el sistema de telemetría de la Dirección General de Aguas para obtener niveles de ríos y caudales en tiempo real, permitiendo actualizar las probabilidades de falla de forma dinámica cuando se detecten condiciones de alerta.
- 2) **Incorporación de pronósticos meteorológicos:** Integrar modelos de predicción de precipitación de corto plazo (1-6 horas) de la Dirección Meteorológica de Chile para anticipar zonas de riesgo antes de que ocurran los eventos, habilitando ruteo preventivo.
- 3) **Desarrollo de aplicación móvil:** Crear una aplicación nativa para iOS y Android que proporcione navegación resiliente turn-by-turn con notificaciones push sobre cambios en condiciones de riesgo durante el viaje.
- 4) **Modelos de Machine Learning:** Entrenar modelos de aprendizaje automático utilizando datos históricos de inundaciones y condiciones meteorológicas para mejorar la precisión de las predicciones de probabilidad de falla, potencialmente utilizando redes neuronales recurrentes (LSTM) para capturar patrones temporales.
- 5) **Evaluación de usabilidad con usuarios:** Conducir estudios de usuario con conductores reales en Santiago para evaluar la aceptabilidad de rutas más largas pero más seguras, y optimizar la presentación de información de riesgo en la interfaz.
- 6) **Extension a otras ciudades chilenas:** Adaptar el sistema para ciudades con problemáticas similares como Concepción, Valparaíso y Talca, donde las inundaciones urbanas también representan un desafío significativo para la movilidad.
- 7) **Optimización de tiempos CPLEX:** Investigar técnicas de descomposición (Benders, Dantzig-Wolfe) y paralelización para reducir los tiempos de cómputo del modelo MILP a niveles aceptables para uso interactivo.
- 8) **Extension a transporte multimodal:** Incorporar modos de transporte adicionales (metro, buses, bicicletas) considerando que diferentes modos tienen diferentes vulnerabilidades ante inundaciones.

D. Impacto Potencial

El sistema desarrollado tiene potencial de impacto en múltiples dimensiones:

- **Seguridad vial:** Reducción de accidentes vehiculares relacionados con inundación, que actualmente suman más de 120 casos anuales en Santiago.
- **Eficiencia del transporte:** Minimización de tiempos perdidos por vías bloqueadas, con ahorros estimados en millones de horas-persona anuales durante temporada de lluvias.

- **Servicios de emergencia:** Rutas más confiables para ambulancias, bomberos y carabineros durante eventos climáticos adversos.
- **Planificación urbana:** Identificación de puntos críticos de la red vial que requieren inversión en infraestructura de drenaje.
- **Replicabilidad:** Metodología aplicable a otras ciudades latinoamericanas con desafíos similares de inundación urbana.

AGRADECIMIENTOS

Se agradece a OpenStreetMap, Supabase, IBM (licencia CPLEX), y organismos gubernamentales chilenos (DGA, SERNAGEOMIN, MMA) por la disponibilidad de datos.

DISPONIBILIDAD DEL CÓDIGO

El código fuente completo del sistema, incluyendo el pipeline ETL, algoritmos de ruteo, y aplicación web, está disponible públicamente en GitHub:

<https://github.com/felipearosr/ruteo>

El repositorio incluye documentación para replicar el sistema, scripts de configuración de base de datos, y datos de ejemplo para pruebas.

REFERENCIAS

- Bruneau, M., Chang, S. E., Eguchi, R. T., Lee, G. C., O'Rourke, T. D., Reinhorn, A. M., ... & von Winterfeldt, D. (2003). A framework to quantitatively assess and enhance the seismic resilience of communities. *Earthquake Spectra*, 19(4), 733-752.
- Chen, B. Y., Li, Q., Wang, D., Shaw, S. L., Lam, W. H., Yuan, H., & Fang, Z. (2019). Reliable shortest path finding in stochastic networks with spatial correlated link travel times. *Transportation Research Part B: Methodological*, 129, 90-113.
- Cova, T. J., & Johnson, J. P. (2003). A network flow model for lane-based evacuation routing. *Transportation Research Part A: Policy and Practice*, 37(7), 579-604.
- Dijkstra, E. W. (1959). A note on two problems in connexion with graphs. *Numerische Mathematik*, 1(1), 269-271.
- Garreaud, R. D., Boisier, J. P., Rondanelli, R., Montecinos, A., Sepúlveda, H. H., & Veloso-Aguila, D. (2020). The Central Chile mega drought (2010-2018): A climate dynamics perspective. *International Journal of Climatology*, 40(1), 421-439.
- Garrido, R. A., & Mahmassani, H. S. (2000). Forecasting freight transportation demand with the space-time multinomial probit model. *Transportation Research Part B: Methodological*, 34(5), 403-418.
- Haklay, M. (2010). How good is volunteered geographical information? A comparative study of OpenStreetMap and Ordnance Survey datasets. *Environment and Planning B: Planning and Design*, 37(4), 682-703.
- Hart, P. E., Nilsson, N. J., & Raphael, B. (1968). A formal basis for the heuristic determination of minimum cost paths. *IEEE Transactions on Systems Science and Cybernetics*, 4(2), 100-107.
- Intergovernmental Panel on Climate Change [IPCC]. (2021). *Climate Change 2021: The Physical Science Basis. Contribution of Working Group I to the Sixth Assessment Report*. Cambridge University Press.
- Mattsson, L. G., & Jenelius, E. (2015). Vulnerability and resilience of transport systems: A discussion of recent research. *Transportation Research Part A: Policy and Practice*, 81, 16-34.
- Ministerio de Obras Públicas [MOP]. (2019). *Catastro de pasos bajo nivel con antecedentes de anegamiento en la Región Metropolitana*. Dirección de Vialidad, Gobierno de Chile.
- Murray-Tuite, P. M., & Mahmassani, H. S. (2006). Methodology for determining vulnerable links in a transportation network. *Transportation Research Record*, 1964(1), 94-102.
- Pregolato, M., Ford, A., Wilkinson, S. M., & Dawson, R. J. (2017). The impact of flooding on road transport: A depth-disruption function. *Transportation Research Part D: Transport and Environment*, 55, 67-81.
- Servicio Nacional de Geología y Minería [SERNAGEOMIN]. (2020). *Mapa de peligros geológicos de la Región Metropolitana de Santiago* (Carta Geológica de Chile, Serie Geología Ambiental No. 1). Gobierno de Chile.
- Suárez, P., Anderson, W., Mahal, V., & Lakshmanan, T. R. (2005). Impacts of flooding and climate change on urban transportation: A systemwide performance assessment of the Boston Metro Area. *Transportation Research Part D: Transport and Environment*, 10(3), 231-244.
- Wolsey, L. A. (1998). *Integer Programming*. John Wiley & Sons.

APÉNDICE

A. Código Principal

Probabilidad (SQL): UPDATE infra_aristas SET p_fallo = 0.4*EXP(-d_rio/500) + 0.3*EXP(-d_dga/1000) + 0.2*EXP(-d_rep/200)

Dijkstra Resiliente: cost = length_m * (1 + k * p_fallo_arista)

CPLEX MILP: min $\sum x_e(l_e + \lambda l_{pe})$ sujeto a conservación de flujo

A*: $f(n) = g(n) + h(n)$, donde g incluye penalización de riesgo y h es distancia euclidiana

B. Esquema de Base de Datos

Tablas principales: infra_nodos (28,208), infra_aristas (33,947), amenaza_dga (94), amenaza_rios (58), amenaza_pasos_bajo_nivel (20), amenaza_reportes (25). Código completo disponible en: <https://github.com/felipearosr/ruteo>